

Características de Repositórios Populares no GitHub

Autores: Kaio Henrique Oliveira da Silveira Barbosa

Introdução

Este estudo empírico investiga as características de repositórios populares na plataforma GitHub, utilizando uma amostra de 1000 projetos coletados através da API GraphQL. O objetivo central é analisar aspectos como maturidade, colaboração, manutenção e tecnologia, por meio de métricas observáveis e reproduzíveis. A pesquisa foi estruturada em três etapas principais: validação da coleta de dados e queries, escalabilidade da coleta com paginação e persistência dos dados em formato CSV, e análise estatística aprofundada, incluindo visualizações e tomada de decisão baseada em hipóteses. A metodologia de análise emprega medidas de tendência central, distribuição e concentração, permitindo uma compreensão abrangente não apenas dos valores médios, mas também da assimetria e variabilidade inerente aos projetos analisados.

Questões de Pesquisa e Hipóteses

As seguintes questões de pesquisa (RQs) foram formuladas para guiar este estudo, acompanhadas de suas respectivas hipóteses:

- **RQ01: Sistemas populares são maduros/antigos?**
 - **Hipótese:** Sistemas populares tendem a ser mais antigos.
- **RQ02: Sistemas populares recebem muita contribuição externa?**
 - **Hipótese:** Sistemas populares apresentam alto volume de Pull Requests (PRs) aceitas.
- **RQ03: Sistemas populares lançam releases com frequência?**
 - **Hipótese:** Sistemas populares lançam releases regularmente.

- **RQ04: Sistemas populares são atualizados com frequência?**
 - **Hipótese:** Sistemas populares são atualizados recentemente.
- **RQ05: Sistemas populares são escritos nas linguagens mais populares?**
 - **Hipótese:** Linguagens predominantes incluem JavaScript, Python, Java e TypeScript.
- **RQ06: Sistemas populares possuem alto percentual de issues fechadas?**
 - **Hipótese:** O percentual de fechamento de issues é alto.

Objetivo

O objetivo geral deste trabalho é responder quantitativamente às seis questões de pesquisa (RQs) propostas, utilizando dados reais coletados nas etapas anteriores. Para isso, será empregada análise estatística descritiva e visualizações para fundamentar as decisões sobre as hipóteses. Especificamente, busca-se:

- Medir a maturidade dos projetos (idade).
- Medir a intensidade da contribuição externa (PRs merged).
- Medir a regularidade de releases.
- Medir a recência da manutenção (dias desde a última atualização).
- Identificar a concentração tecnológica (linguagens de programação predominantes).
- Avaliar a saúde operacional (razão de issues fechadas).

Além de confirmar ou refutar cada hipótese, este estudo visa explicar o comportamento das distribuições observadas e os possíveis fatores que levam à concentração de valores extremos.

Metodologia

A metodologia adotada para este estudo compreendeu as seguintes etapas:

1. **Coleta de Dados:** Leitura do arquivo CSV `docs/Sprint2/repositorios.csv`, resultante da Sprint 2 do projeto, contendo os dados dos repositórios.

2. **Pré-processamento:** Limpeza e normalização dos dados numéricos para garantir a consistência e a qualidade da análise.
3. **Análise Estatística Descritiva:** Cálculo de métricas de tendência central, como média e mediana, para cada questão de pesquisa (RQ).
4. **Visualização de Dados:** Geração de gráficos de distribuição e frequência para ilustrar as características dos dados.
5. **Interpretação e Decisão:** Interpretação dos resultados estatísticos e visuais para tomar decisões informadas sobre a confirmação ou refutação das hipóteses.

Regras de Decisão

As seguintes regras de decisão foram estabelecidas para avaliar as hipóteses:

- **RQ01:** Hipótese confirmada se a mediana da idade dos repositórios for maior ou igual a 5 anos.
- **RQ02:** Hipótese confirmada se a mediana de PRs merged for maior ou igual a 100.
- **RQ03:** Hipótese confirmada se a mediana de releases for maior ou igual a 10.
- **RQ04:** Hipótese confirmada se a mediana de dias desde a última atualização for menor ou igual a 30 dias.
- **RQ05:** Hipótese confirmada se ao menos 3 das linguagens esperadas (JavaScript, Python, Java, TypeScript) aparecerem entre as 10 mais frequentes.
- **RQ06:** Hipótese confirmada se a mediana da razão de issues fechadas for maior ou igual a 80%.

Resultados

Os resultados da análise estatística descritiva e da avaliação das hipóteses são apresentados a seguir. Todas as hipóteses foram confirmadas com base nas regras de decisão estabelecidas.

Tabela de Respostas das RQs

RQ	Métrica Analisada	Valor Numérico	Resposta
RQ01	Mediana da idade dos repositórios	8.39 anos	Sim
RQ02	Mediana de PRs merged	739	Sim
RQ03	Mediana de releases	40	Sim
RQ04	Mediana de dias desde atualização	0 dias	Sim
RQ05	Top linguagens	Python, TypeScript, JavaScript, Não especificada, Go	Sim
RQ06	Mediana da razão de issues fechadas	87.78%	Sim

Tabela de Linguagens (Top 10)

Posição	Linguagem	Quantidade	Percentual
1	Python	200	20.00%
2	TypeScript	160	16.00%
3	JavaScript	115	11.50%
4	Não especificada	95	9.50%
5	Go	77	7.70%
6	Rust	54	5.40%
7	Java	47	4.70%
8	C++	46	4.60%
9	C	25	2.50%
10	Jupyter Notebook	23	2.30%

Métricas Gerais

- **Total de repositórios analisados:** 1000
- **Faixa de estrelas:** 29.574 a 472.576
- **Média de estrelas:** 58017
- **Média de idade:** 8.19 anos
- **Média de PRs merged:** 3956
- **Média de releases:** 120.67
- **Média de dias desde atualização:** 0.00 dias
- **Média da razão de issues fechadas:** 80.57%


Métricas Avançadas (Distribuição)

Métrica	Q1 (25%)	Mediana (50%)	Q3 (75%)	P90	P95
Idade (anos)	5.01	8.39	11.42	13.57	14.75
PRs merged	173.50	739.00	3207.25	9586.90	18266.40
Releases	0.00	40.50	145.00	334.20	558.05
Razão de issues fechadas	71.75%	87.78%	96.07%	98.98%	99.66%


Métricas de Atividade Recente

- **Repositórios atualizados no mesmo dia da coleta:** 997 / 1000 (99.7%)
- **Repositórios atualizados em até 7 dias:** 1000 / 1000 (100%)
- **Repositórios atualizados em até 30 dias:** 1000 / 1000 (100%)
- **Participação das 5 linguagens mais frequentes:** 64.7% do total


Gráficos (Descrições)




- **Top Linguagens:** Este gráfico de barras ilustra a frequência das linguagens primárias nos 1000 repositórios analisados, indicando uma forte concentração em Python, TypeScript e JavaScript. Isso sugere a predominância de ecossistemas amplamente adotados em projetos de alta visibilidade.



- **Distribuição de Idade:** O boxplot de idade demonstra a distribuição dos projetos por faixa etária. A mediana de 8.39 anos e o quartil superior acima de 11 anos reforçam a ideia de que repositórios populares tendem a ser maduros, com um histórico de evolução mais longo.



- **Distribuição de Issues Fechadas:** Este boxplot destaca a distribuição da razão de fechamento de issues. A concentração em valores altos (com mediana de 87.78%) indica que a maioria dos projetos analisados mantém uma rotina consistente de triagem e resolução de problemas.



- **Boxplot de PRs:** O boxplot resume a dispersão e assimetria dos PRs merged. A distância entre a mediana e os limites superiores, juntamente com a presença de valores extremos, revela que um pequeno número de projetos concentra um volume muito alto de contribuições, enquanto a maioria mantém níveis moderados.
- **Distribuição de Estrelas:** O histograma de estrelas evidencia a heterogeneidade da popularidade dentro da amostra. Embora todos os projetos sejam populares, a distribuição mostra diferentes “níveis” de popularidade, com uma cauda longa para repositórios excepcionalmente estrelados.
- **Relação entre Estrelas e PRs:** O gráfico de dispersão (com escalas log/symlog) permite analisar a associação entre popularidade e contribuição externa. Observa-se uma tendência positiva geral, mas com ampla variabilidade: projetos com estrelas semelhantes podem apresentar volumes bem diferentes de PRs merged.

Discussões

Os insights derivados da análise dos dados revelam padrões importantes sobre os repositórios populares no GitHub:

- **Maturidade e Popularidade:** A maturidade observada, com uma mediana de idade de 8.39 anos, sugere uma forte associação entre popularidade e uma trajetória de evolução e estabilização de longo prazo.
- **Colaboração Externa:** A colaboração externa é notavelmente alta, porém desigual. A mediana de 739 PRs merged contrasta com percentis superiores muito elevados, indicando que a contribuição é concentrada em um subconjunto específico de projetos.
- **Frequência de Releases:** O comportamento das releases é heterogêneo. Embora muitos projetos apresentem alta frequência, uma parcela significativa possui poucas releases, o que aponta para diferentes estratégias de versionamento adotadas.
- **Manutenção Ativa:** A recência de atualização é extremamente alta, com 99.7% dos repositórios atualizados no mesmo dia da coleta e 100% em até 7 dias. Isso reforça um cenário de manutenção ativa e contínua na amostra estudada.
- **Tendências Tecnológicas:** A composição das linguagens de programação confirma as tendências atuais da indústria, com a predominância de stacks modernas e amplamente adotadas pela comunidade.
- **Saúde Operacional:** A elevada razão de issues fechadas (mediana de 87.78%) demonstra uma boa capacidade operacional de resposta, triagem e resolução de problemas na maioria dos repositórios.
- **Fatores de Popularidade:** Em conjunto, os resultados indicam que a popularidade de um projeto não é determinada por um único fator, mas sim pela combinação de maturidade, atividade contínua, engajamento externo e uma governança técnica eficaz.

Conclusão e Tomadas de Decisão

Com base nas regras de decisão estabelecidas na metodologia, todas as hipóteses formuladas foram confirmadas. Isso sugere que, na amostra analisada, repositórios populares no GitHub tendem a apresentar uma combinação de maturidade histórica,

manutenção recente, capacidade de colaboração externa e uma boa saúde operacional.

Resumo das Decisões:

- **RQ01:** Hipótese confirmada, com mediana de idade de 8.39 anos (acima do limiar de 5 anos).
- **RQ02:** Hipótese confirmada, com mediana de PRs merged de 739 (acima do limiar de 100).
- **RQ03:** Hipótese confirmada, com mediana de releases de 40 (acima do limiar de 10).
- **RQ04:** Hipótese confirmada, com mediana de dias desde a última atualização de 0 (abaixo do limiar de 30 dias).
- **RQ05:** Hipótese confirmada, com as linguagens esperadas aparecendo entre as mais frequentes.
- **RQ06:** Hipótese confirmada, com mediana da razão de issues fechadas de 87.78% (acima do limiar de 80%).

Como implicação prática, os resultados sugerem que projetos populares e bem-sucedidos mantêm um ciclo ativo de atualização, governança eficiente de issues e uma postura aberta à colaboração. É importante notar que, como limitação, esta análise representa uma “fotografia” temporal da plataforma e seus resultados podem variar dependendo da janela de coleta, dos critérios de busca e da dinâmica em constante evolução do ecossistema GitHub.